COULIBALY ABOUBAKAR · Data Scientist

Prédire la Ligue 1 Côte d'Ivoire

De la collecte web au réseau de neurones : une plateforme de données complète sur dix saisons de MTN Ligue 1 (2016 → 2026)

10	1 934	30 %	44%
saisons complètes + 2026-27 en cours	matchs joués	de matchs nuls	précision du meilleur modèle (naïf : 35%)

Résumé

Les données du championnat ivoirien sont dispersées et peu exploitées. Ce projet construit une chaîne complète : collecte automatisée et respectueuse des sites (RSSSF, Wikipédia, Futbol24, API-Football), zone brute **MongoDB**, modèle relationnel **PostgreSQL** conçu selon Merise, analyses SQL et réseau, six modèles de prédiction du résultat (victoire domicile, nul, victoire extérieur) dont un **réseau de neurones PyTorch**, et un tableau de bord **Streamlit**.

Le championnat est **serré et peu prolifique** : 30 % de nuls, 2.06 buts par match, un avantage du terrain faible (36 % de victoires à domicile). L'ASEC Mimosas domine (6 titres sur 10) et occupe le centre du réseau des transferts.

En validation temporelle glissante sur 1141 matchs, le modèle **Elo** obtient la meilleure log-loss (1.0715 contre 1.0974 pour la référence naïve) et une précision de 43.7% (naïf : 35.4%). Le gain est statistiquement significatif (bootstrap, IC 95 % [-0.0392 ; -0.0092]). Les modèles complexes, dont le réseau de neurones, n'apportent pas de gain avec ~1 500 matchs d'entraînement : un résultat honnête, cohérent avec la littérature sur la prédiction du football.

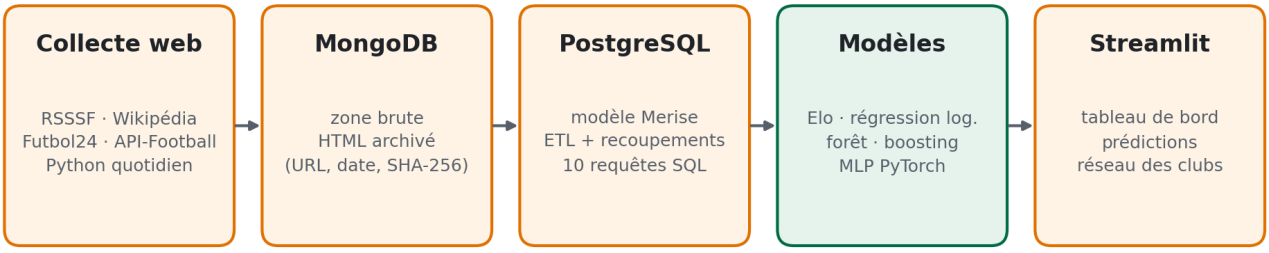


Figure 1 — Architecture : chaque base a un rôle unique.

Objectif et impact

La Ligue 1 ivoirienne forme des joueurs pour toute l'Afrique et l'Europe, mais ses données sont dispersées, incomplètes et presque jamais analysées. **L'objectif est de les rassembler dans une base fiable, sourcée et gratuite**, pour que les acteurs du football ivoirien décident avec des faits plutôt qu'avec des impressions. Chaque usage ci-dessous s'appuie sur un constat mesuré dans les données.

Pour qui	Ce que ça change	Constat mesuré
Clubs et entraîneurs	Mesurer sa performance sans cellule data	CO Korhogo prend moins de points à domicile (0.89 par match) qu'à l'extérieur (1.28) : un axe de travail concret.
Joueurs, agents, recruteurs	Rendre visibles les talents locaux	563 départs suivis vers 402 clubs hors Ligue 1, dont 42% depuis la seule ASEC : les joueurs des autres clubs restent peu exposés.
Médias et supporters	Débattre avec des chiffres vérifiés	Scores recoupés entre trois sources (11 écarts signalés) ; probabilités de match expliquées plutôt qu'un pronostic tranché.
Ligue et Fédération	Piloter l'équilibre du championnat	6 titres sur 10 pour l'ASEC, 30 % de nuls, 2.06 buts par match : des indicateurs pour évaluer le format, le calendrier et l'attractivité.

Ce que ce projet n'est pas : un outil de paris. Les probabilités servent à comprendre le championnat et à situer une affiche, pas à miser.

1. Données : sources, volumes, qualité

Un audit des sources a été mené avant toute collecte : couverture, conditions d'utilisation et *robots.txt*. Soccerway/Flashscore (CGU interdisant le scraping), Transfermarkt (championnat non suivi) et Wikidata (SPARQL interdit par robots.txt) ont été écartés.

Source	Données	Couverture
RSSSF	tous les matchs, classements officiels	2016-17 → 2025-26
Wikipédia FR/EN	stades, buteurs, grilles, ~460 carrières	11 saisons
Futbol24	résultats et calendrier daté	saison en cours
API-Football	matchs, effectifs, transferts, événements	2022-23 → 2024-25

Traçabilité. Chaque page est archivée dans MongoDB avec son URL, sa date et une empreinte SHA-256 ; on peut re-parser sans re-télécharger. Collecte quotidienne planifiée, pause de 2 s entre requêtes, quota API respecté (100/jour) avec reprise automatique.

ETL et contrôles. L'ETL ramène 102 variantes de noms à 31 clubs, recoupe les scores entre sources (11 divergences sur ~2 000 matchs, toutes journalisées) et vérifie que les classements recalculés sont identiques aux classements officiels sur les 10 saisons. Le modèle relationnel (MCD → MLD → MPD) compte 12 tables et une vue ; 4 vues matérialisées et 10 requêtes SQL documentées (fonctions de fenêtre, CTE « gaps and islands ») alimentent le tableau de bord.

Saison	Matchs	Domicile	Nul	Extérieur	Buts/match
2016-2017	182	35.7 %	34.1 %	30.2 %	1.80
2017-2018	182	39.0 %	35.2 %	25.8 %	1.99
2018-2019	181	41.4 %	27.1 %	31.5 %	2.15
2019-2020	140	33.6 %	30.7 %	35.7 %	2.22
2020-2021	95	33.7 %	34.7 %	31.6 %	1.91

2021-2022	182	36.8 %	26.4 %	36.8 %	2.15
2022-2023	240	38.8 %	31.3 %	30.0 %	2.10
2023-2024	239	37.7 %	28.9 %	33.5 %	2.15
2024-2025	240	30.0 %	30.8 %	39.2 %	2.14
2025-2026	240	33.8 %	26.7 %	39.6 %	2.00
2026-2027	13	23.1 %	38.5 %	38.5 %	1.38

Tableau 1 — Matchs joués et répartition des résultats par saison (requête 06). 2019-20 : arrêt Covid ; 2020-21 : poules + play-off.

Limites des données. Aucune source légale ne publie les buteurs et cartons match par match avant 2022 ; les effectifs complets n'existent que via API-Football (2022-2025) ; les carrières Wikipédia sont biaisées vers les grands clubs et les joueurs partis à l'étranger.

2. Analyse exploratoire

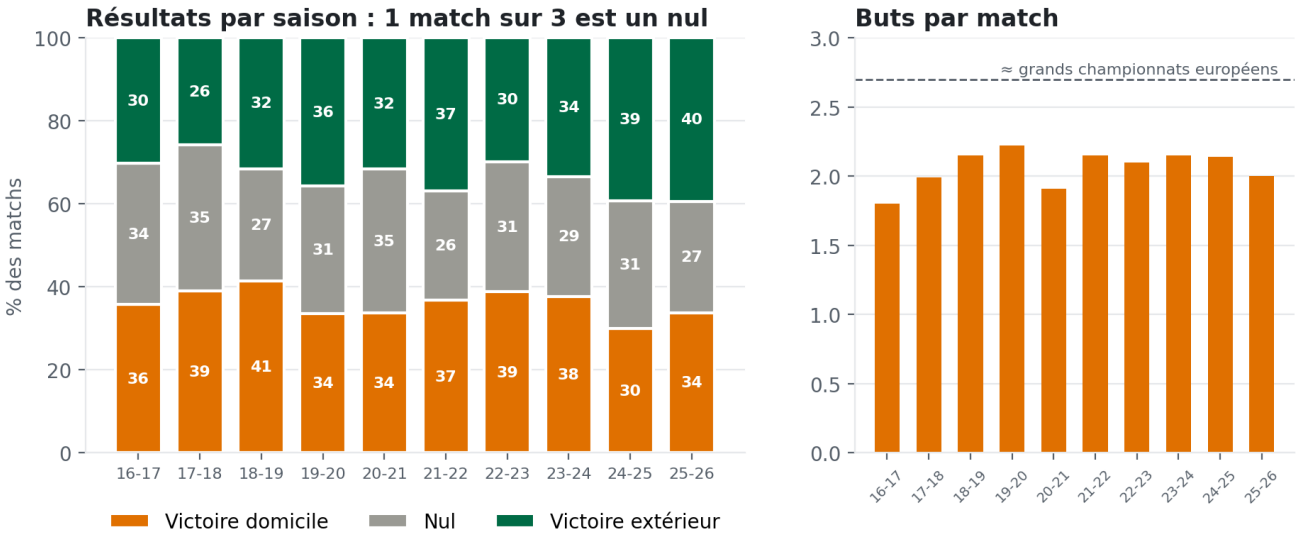


Figure 2 — Un tiers de nuls et ~2 buts par match, toutes saisons confondues.

Le premier constat conditionne toute la suite : **30 % des matchs se terminent par un nul** (≈ 25 % en Europe) et le total moyen est de 2.06 buts. Les scores 1-1, 1-0, 0-0 et 0-1 représentent à eux seuls plus de la moitié des matchs (figure 3). Le nombre de buts suit approximativement une loi de Poisson.

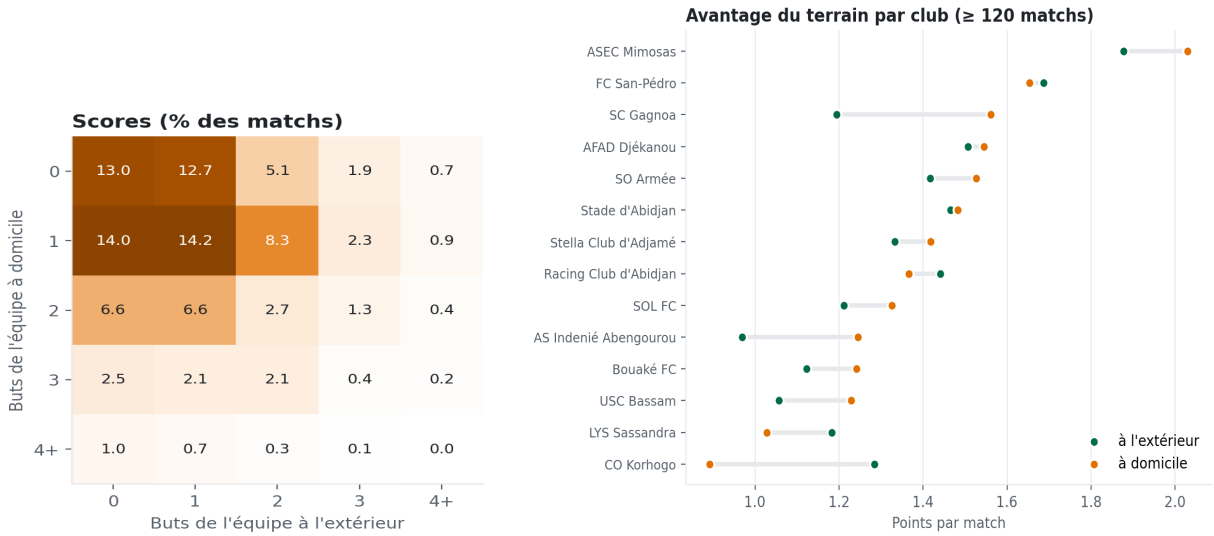


Figure 3 — Fréquence des scores (gauche) ; avantage du terrain par club (droite).

L'**avantage du terrain** existe (36 % de victoires à domicile contre 34 % à l'extérieur) mais il est faible et instable : il s'est inversé en 2025-26. Il varie fortement selon les clubs, certains clubs de province prenant nettement plus de points chez eux.

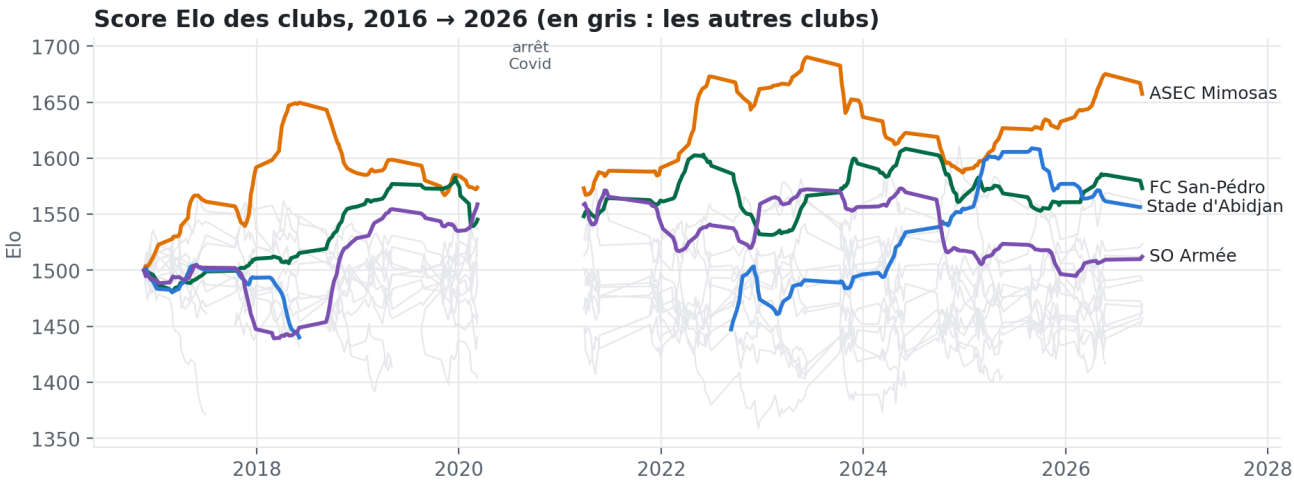


Figure 4 — Score Elo reconstruit match après match (lissé).

Le score Elo, recalculé après chaque match, résume la hiérarchie : l'ASEC Mimosas domine la période (6 titres, une série record de 30 matchs sans défaite), tandis que FC San-Pédro et le Stade d'Abidjan ont émergé récemment (titres 2024 et 2025).

3. Réseau des clubs

Les carrières Wikipédia et les transferts API-Football donnent 961 mouvements de joueurs entre 564 clubs. Le graphe orienté pondéré est analysé avec les mêmes algorithmes que Neo4j Graph Data Science : **PageRank** (centralité), intermédiarité et **communautés de Louvain**.

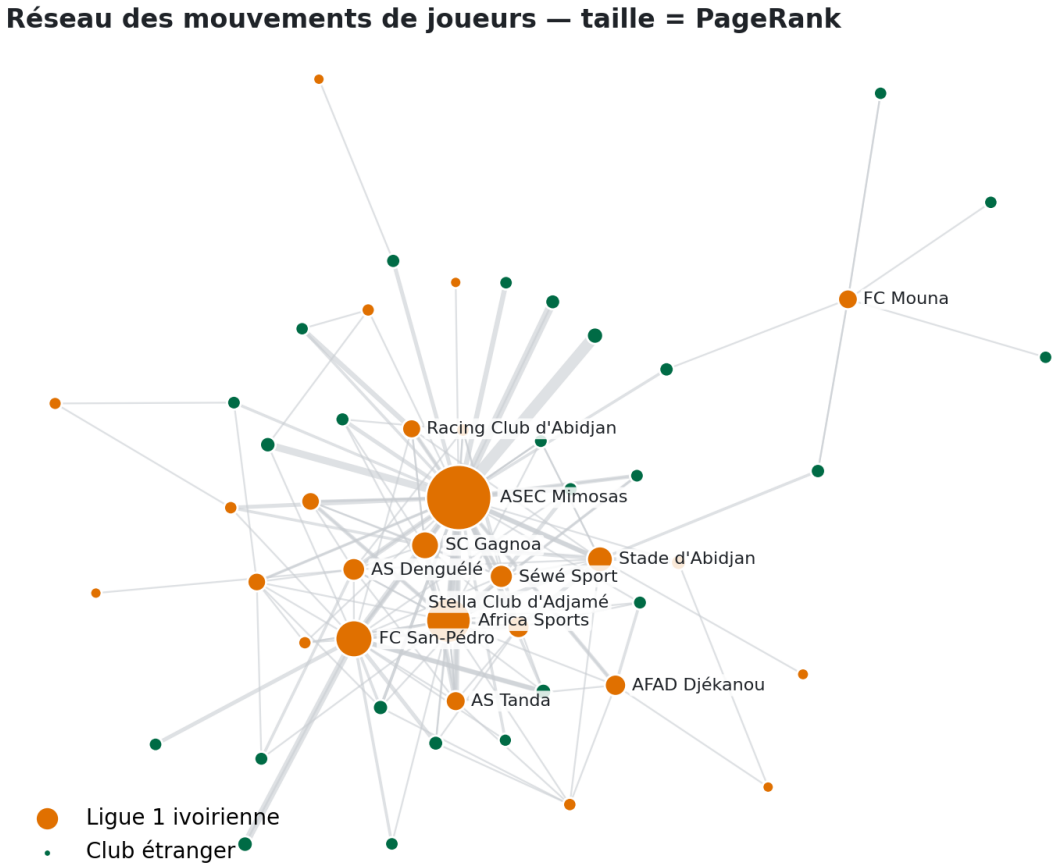


Figure 5 — Clubs de Ligue 1 (orange) et clubs étrangers les plus centraux (vert) ; taille proportionnelle au PageRank.

Clubs les plus centraux : ASEC Mimosas (0.099), Africa Sports (0.045), FC San-Pédro (0.030), SC Gagnoa (0.016), Stade d'Abidjan (0.014), Séwé Sport (0.011). L'ASEC Mimosas est de loin le club le plus central, notamment par ses liens avec Beveren (Belgique), partenaire historique de son académie. Principales destinations à l'étranger : Beveren, Young Africans, CS Sfaxien, Shirak, Charlton Athletic. Ce réseau est biaisé vers les clubs dont les joueurs ont un article Wikipédia.

4. Modélisation

4.1 Variables et protocole

Cible : résultat en 3 classes (D, N, E). **26 variables**, toutes calculées avec l'information disponible *avant* le match en parcourant les matchs dans l'ordre chronologique : Elo des deux équipes (K = 15, réglé en validation, retour partiel vers la moyenne entre saisons, promus à 1 450), forme sur 5 et 10 matchs, buts marqués et encaissés glissants, points par match, différence de buts et rang dans la saison, forme à domicile / à l'extérieur, jours de repos, et écarts entre les deux équipes.

Aucun découpage aléatoire : 2016-17 initialise l'Elo ; chaque saison 2021-22 → 2025-26 est prédite par un modèle entraîné sur toutes les saisons précédentes (validation glissante, 1141 matchs). Le modèle retenu est **le plus simple** parmi ceux dont la log-loss moyenne 2021 → 2024 est à moins de 0,002 de la meilleure (écart négligeable devant l'incertitude) ; la saison 2025-26 sert de **test final** et n'intervient dans aucun choix.

4.2 Modèles comparés

- **Référence naïve** : toujours « domicile », probabilités = fréquences observées.
- **Elo** : régression logistique sur le seul écart Elo.
- **Régression logistique multinomiale** standardisée, régularisation C = 0.003 choisie en validation.
- **Forêt aléatoire** (400 arbres, feuilles ≥ 25) et **gradient boosting** (profondeur 3, arrêt anticipé).
- **Réseau de neurones PyTorch** : couches [16], dropout 0.2, pénalité L2 0.001, arrêt anticipé sur les matchs les plus récents, moyenne de 5 initialisations ; architecture choisie par recherche sur grille.

Métriques : précision, log-loss (qualité des probabilités, métrique principale), score de Brier et RPS (ranked probability score, qui tient compte de l'ordre D > N > E), matrice de confusion et calibration.

4.3 Résultats

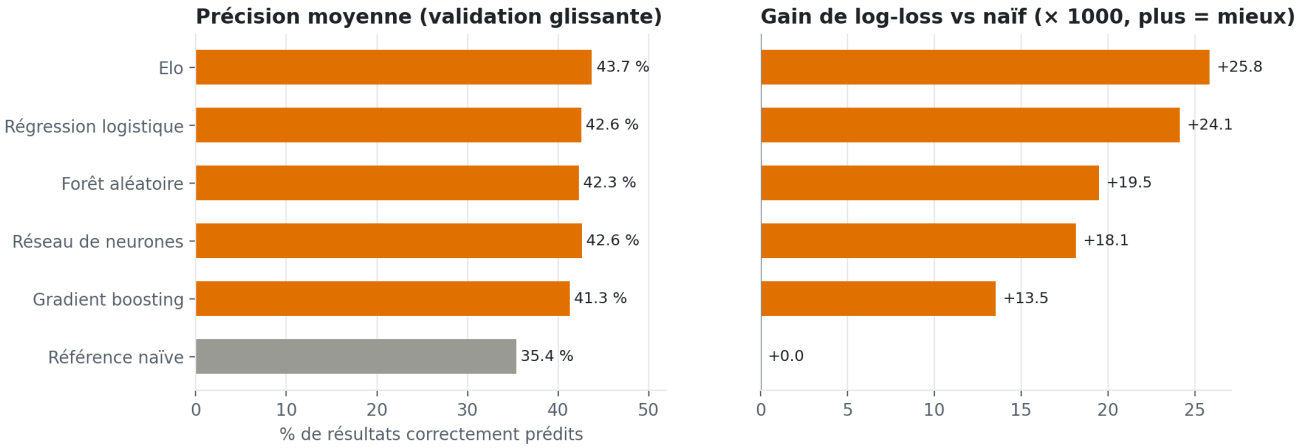


Figure 6 — Moyennes de la validation glissante (5 saisons).

Modèle	Précision	Log-loss	Brier	RPS
Elo	43.7%	1.0715	0.6473	0.2207
Régression logistique	42.6%	1.0732	0.6487	0.2220
Forêt aléatoire	42.3%	1.0779	0.6517	0.2230
Réseau de neurones (MLP)	42.6%	1.0792	0.6526	0.2236
Gradient boosting	41.3%	1.0838	0.6559	0.2244
Référence naïve	35.4%	1.0974	0.6659	0.2302

Tableau 2 — Validation glissante 2021-22 → 2025-26 (moyennes).

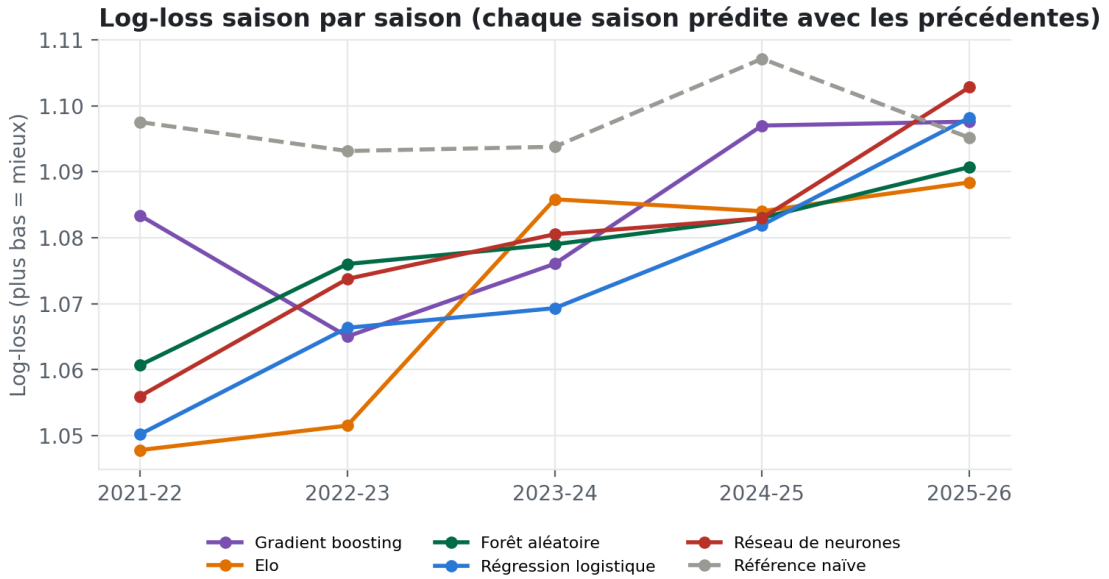


Figure 7 — Log-loss par saison prédite.

Modèle (test 2025-26)	Précision	Log-loss	Brier	RPS
Elo	39.2%	1.0884	0.6575	0.2305
Forêt aléatoire	40.0%	1.0907	0.6598	0.2306
Référence naïve	33.8%	1.0952	0.6645	0.2338
Gradient boosting	40.4%	1.0976	0.6633	0.2310
Régression logistique	38.3%	1.0982	0.6645	0.2323
Réseau de neurones (MLP)	38.8%	1.1028	0.6675	0.2338

Tableau 3 — Test final sur 2025-26 (240 matchs). Saison atypique : 40% de victoires à l'extérieur contre 34% à domicile.

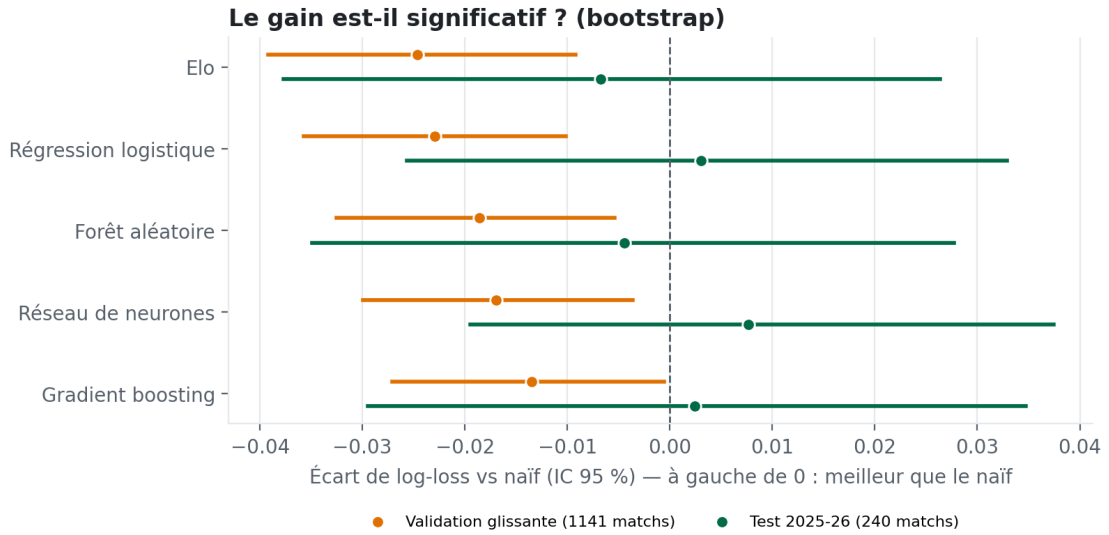


Figure 8 — Écart de log-loss avec la référence naïve et intervalle de confiance à 95 % (bootstrap apparié, 2 000 tirages).

Lecture. Sur l'ensemble de la validation glissante, Elo réduit la log-loss de 0.0258 et gagne 8.3 points de précision. Sur la seule saison de test (240 matchs), les intervalles de confiance sont trop larges pour départager les modèles : une saison ne suffit pas à conclure, d'où l'intérêt de la validation glissante. Le réseau de neurones bat lui aussi la référence naïve, mais reste derrière Elo et la régression logistique : avec ~1 500 matchs et des variables déjà synthétiques (Elo, forme), il n'y a pas d'interaction non linéaire exploitable.

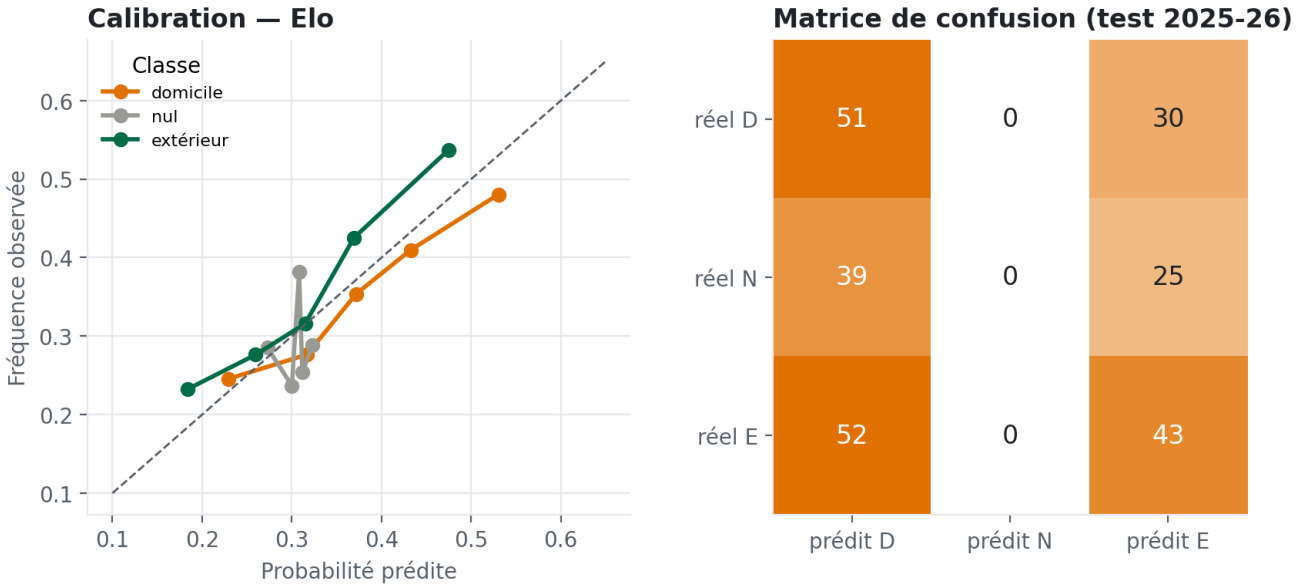


Figure 9 — Calibration du modèle retenu (Elo) sur la validation glissante ; matrice de confusion du test.

Les probabilités sont correctement calibrées (points proches de la diagonale). Le **nul reste la classe la plus difficile** : le modèle retenu ne le prédit jamais sur le test, car sa probabilité reste autour de 30 % quel que soit le match et n'est presque jamais la plus élevée. C'est une limite connue de la prédiction en 3 classes : la précision plafonne autour de 45-50 %, y compris pour les bookmakers.

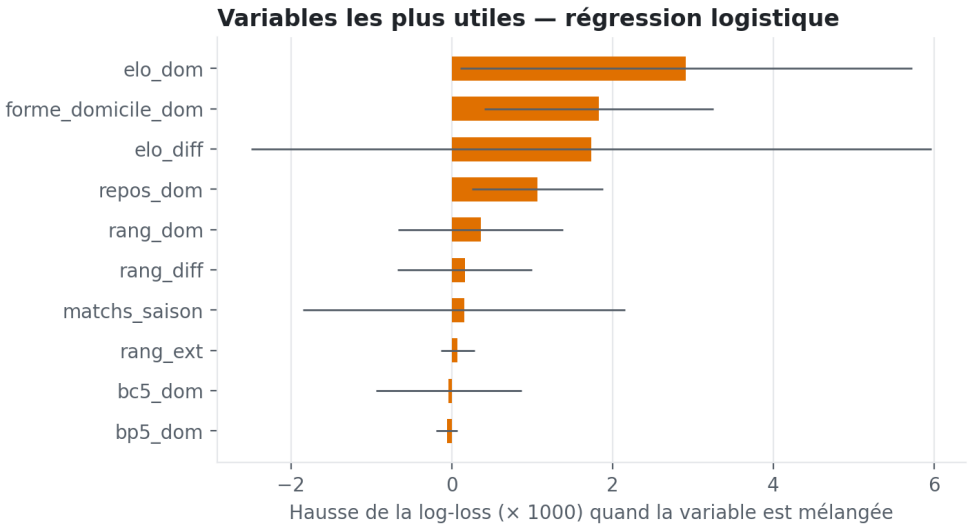


Figure 10 — Importance par permutation (régression logistique, test 2025-26).

Variables les plus utiles : Elo de l'équipe à domicile, forme à domicile de l'équipe qui reçoit, écart Elo, jours de repos (domicile). Le niveau des équipes (Elo) porte l'essentiel de l'information ; les autres variables ont des effets faibles, du même ordre que leur incertitude, ce qui explique que les modèles complexes n'apportent rien de plus.

5. Restitution et déploiement

Le tableau de bord Streamlit (7 pages : Accueil avec la carte des clubs, Championnat, Clubs, Réseau, Prédiction, Modèles, Données & Méthodologie) lit uniquement des fichiers Parquet exportés depuis PostgreSQL et les résultats du modèle : il se déploie sur Streamlit Community Cloud sans exposer les bases. La page Prédiction donne les probabilités des matchs à venir de 2026-27 et un simulateur pour toutes les affiches.

Commande	Effet
make db	lance MongoDB, PostgreSQL, Neo4j (Docker Compose)
make collect	collecte web + API (reprise automatique du quota)
make etl	MongoDB → PostgreSQL, contrôles, vues matérialisées
make train	réglages, validation glissante, test, modèle final
make export	données du tableau de bord (Parquet)
make rapport	figures + ce rapport PDF
make app	tableau de bord en local

6. Limites

- **Volume** : ~240 matchs par saison ; les écarts entre modèles sont du même ordre que l'incertitude d'une saison.
- **Variables manquantes** : compositions, blessures, buteurs et cartons match par match (seulement 2022-2025 via API-Football), cotes des bookmakers.
- **Réseau** biaisé vers les joueurs ayant un article Wikipédia.
- **Formats irréguliers** : saison 2019-20 interrompue, 2020-21 en poules ; classements recalculés approximatifs pour ces deux saisons.

7. Pistes d'amélioration

- Modèle de **Poisson bivarié / Dixon-Coles** pour prédire le score et mieux estimer la probabilité de nul.
- Intégrer les **événements de match** API-Football (en cours de collecte) : forme des buteurs, cartons, absences.
- Charger le graphe dans **Neo4j** (étape suivante du cahier des charges) pour les requêtes de plus court chemin et de coéquipiers communs.
- Évaluer en continu sur 2026-27 : chaque journée jouée devient un nouveau test, ré-entraînement automatique hebdomadaire (GitHub Actions).

Conclusion

Le projet livre une chaîne de données complète et reproductible sur un championnat peu documenté. Côté prédiction, le message est clair : dans une ligue où 30 % des matchs sont nuls, **un bon résumé du niveau des équipes (Elo) vaut mieux qu'un modèle complexe**, et une évaluation honnête — découpage temporel, validation glissante, intervalles de confiance — compte plus que le choix de l'algorithme.

Sources : RSSSF © José Batalha / Rec.Sport.Soccer Statistics Foundation ; Wikipédia (CC BY-SA) ; Futbol24 ; API-Football. Code : dépôt ligue1-ci-data.